




Veri temizleme öncesi Isı Haritası




Veri temizleme öncesi Korelasyon Matrisi




Veri temizleme sonrası Korelasyon Matrisi



Veri temizleme öncesi Mevki Sınıf Dağılımı




Veri temizleme öncesi Kategori Sınıf Dağılımı




Veri temizleme öncesi Oyuncuların Sezon Dağılımı



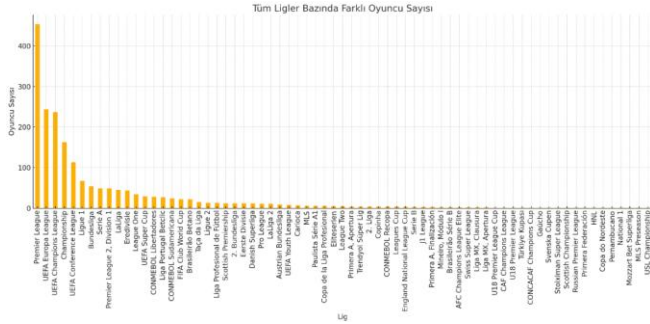
Veri temizleme sonrası Oyuncuların Sezon Dağılımı



Bonservis değer aralığına göre oyuncu dağılımı



Tüm ligler bazında oyuncu dağılımı



II. VERİ MODELLEME

A. Veriyi Model İçin Hazırlama

Öncelikle Autoformer,Informer,Reformer,TFT,TST gibi zaman serisi ve regresyon Transformer modellerine verileceği için veriyi sekansa böldül 5 sekans şablonuna çevirildi.

- Oyuncu Adı → Oyuncu_ID
- Bonservis → Target
- Date = Hedef bonservis değerinin(Target) sezonu

Olarak verilecek modele.

Ham veri model için hazır veriye şu şekilde çevirildi. öncelikle 5 sekans olacağından en az 5 sezon verisine sahip olan oyuncular alındı yani bu durumda 5 sezondan az verisi olan zaten azınlıkta olan oyuncular çıkarıldı.

Oyuncu_ID,Date,t1_performans,t2_performans,t3_performans,t4_performans,t5_performans,Target bu şablona geçildi.

Ligler, Mevkiler ve Kategoriler string değerli olduğundan bu bilgileri **One-hot encoding** ile bildirdik. Bu şablona geçişten sonra

- Satır sayısı: 4835 → 2853
- Sütun sayısı (Feature): 38 → 272
- Form: Uzun form(her satır = oyuncu-sezon)→Geniş form(her satır = oyuncu + geçmiş 5 yıl özellikleri)

Olarak değişti ve modellere doğrudan girdi olarak verilebilecek şekle

B. Modeller

Autoformer, Informer, Reformer, TFT(Temporal Fusion Transformer), TST(Zamansal Füzyon Transformer)

I. Autoformer Modeli

Autoformer, zaman serisi verilerinde uzun dönemli tahmin (forecasting) yapmak için tasarlanmış, dikkat (attention) tabanlı bir derin öğrenme modelidir. 2021 yılında yayınlanan bu model, özellikle klasik Transformer mimarisinin zaman serisi verilerine doğrudan uygulanmasında karşılaşılan zorlukları aşmak için geliştirilmiştir.

Autoformer'ın en büyük farkı, zaman serilerini sezonsal ve trend bileşenlerine ayırmasıdır. Bu ayrıştırma, verinin daha anlamlı şekilde işlenmesini sağlar.

-Nasıl çalışır?

- Zaman serisi = Trend bileşeni + Sezonsal bileşen
- Her bileşen ayrı öğrenilir ve daha sonra birleşerek nihai tahmin üretilir.
- Kendi kendine benzerlikleri (auto-correlation) yakalayarak uzun dönemli örüntüleri öğrenir.Bu sayede mevsimsellik gibi tekrar eden yapıları etkili biçimde modelleyebilir.
- Encoder: Girdi zaman serisini trend ve sezonsal bileşenlere ayırır ve uzun dönemli bağımlılıkları öğrenir.

Decoder: Bu bileşenleri kullanarak gelecekteki değerleri tahmin eder.

Sonuçlar

Epoch	Train Loss	Val Loss	Learning Rate
1	0,8062	0,542	0,0001
2	0,5555	0,4238	0,0001
3	0,4349	0,3531	0,0001
4	0,4038	0,3126	0,0001
5	0,349	0,2933	0,0001
6	0,3314	0,2893	0,0001
7	0,3151	0,2622	0,0001
8	0,299	0,3144	0,0001
9	0,2919	0,2669	0,0001
10	0,2474	0,264	0,0001
11	0,2674	0,2566	0,0001
12	0,2664	0,2963	0,0001
13	0,2555	0,2483	0,0001
14	0,2551	0,2639	0,0001
15	0,2368	0,2667	0,0001
16	0,2554	0,2357	0,0001
17	0,2334	0,2247	0,0001
18	0,2372	0,2318	0,0001
19	0,2219	0,2146	0,0001

20	0,2197	0,2328	0,0001
21	0,221	0,2478	0,0001
22	0,2124	0,2348	0,0001
23	0,2103	0,2774	0,0001
24	0,215	0,2571	0,0001
25	0,2074	0,2016	0,0001
26	0,2041	0,2441	0,0001
27	0,1945	0,2052	0,0001
28	0,1913	0,2023	0,0001
29	0,1791	0,2071	0,0001
30	0,1964	0,2251	0,0001
31	0,1884	0,1866	0,0001
32	0,1879	0,1957	0,0001
33	0,1835	0,2066	0,0001
34	0,1805	0,2006	0,0001
35	0,1724	0,1932	0,0001
36	0,1626	0,225	0,00005
37	0,1675	0,2142	0,00005
38	0,1655	0,2144	0,00005
39	0,1653	0,1982	0,00005
40	0,1655	0,1922	0,00005
41	0,1644	0,195	0,00005

Model 41 epoch boyunca eğitilmiş ve **early stopping** uygulanmıştır. Eğitim ve doğrulama kayıpları istikrarlı biçimde azalmış; öğrenme oranı 36. epoch'tan itibaren azaltılmıştır ($1e-4 \rightarrow 5e-5$). Bu, modelin daha hassas ayarlamalar yapması için uygulanmıştır. Son doğrulama kaybı **0.1950**, eğitim kaybı **0.1644** olarak gerçekleşmiştir.

MSE: 119178858070016.00
MAE: 7788990.00
RMSE: 10916906.98
R²: 0.7911
MAPE: 69.18%
Training Time: 59.60 seconds
Inference Time: 0.0643 seconds

II. Informer Modeli

Informer, uzun dönemli zaman serisi tahmini (Long Sequence Time-Series Forecasting) için özel olarak geliştirilmiş, verimli ve ölçeklenebilir bir Transformer tabanlı derin öğrenme modelidir. 2021 yılında THUML (Tsinghua University) araştırmacıları tarafından geliştirilmiştir.

Informer, klasik Transformer yapısının zaman serilerinde kullanımı sırasında karşılaşılan hesaplama yükü ve doğruluk problemlerini çözme hedefler.

-Nasıl çalışır?

- ProbSparse Self-Attention (Olasılıksal Seyrek Dikkat):

- Klasik attention mekanizması zaman/mekân karmaşıklığını artırır: $O(L^2)O(L^2)O(L^2)$
- Informer bu problemi ProbSparse Attention ile çözer: yalnızca en anlamlı dikkat ağırlıkları hesaplanır.

- Amaç: Uzun dizilerde bilgi yoğunluğu düşük alanları eleyip dikkatli kaynak kullanımı sağlamak

- Self-Attention Distilling (Katman İçinde Bilgi Yoğunlaştırma):

- Uzun zaman dizileri içinde öğrenmeyi zorlaştıran “gereksiz” bilgileri azaltmak için kullanılır.
- Özellikle uzun dizi tahminlerinde modeli daha kompakt ve stabil hale getirir.

-Encoder/Decoder:

- Encoder: Zaman serisini sıkıştırarak anlamlı temsillere dönüştürür.
- Decoder: Bu temsilleri kullanarak gelecekteki değerleri tahmin eder.

Sonuçlar

Epoch	Train Loss	Val Loss	Learning Rate
1	0,7586	0,5742	0,0001
2	0,6814	0,5114	0,0001
3	0,6464	0,4742	0,0001
4	0,5884	0,4368	0,0001
5	0,5383	0,3985	0,0001
6	0,4951	0,3642	0,0001
7	0,4584	0,338	0,0001
8	0,4192	0,3168	0,0001
9	0,3896	0,2993	0,0001
10	0,3532	0,2765	0,0001
11	0,3321	0,2607	0,0001
12	0,3197	0,2495	0,0001
13	0,2975	0,2381	0,0001
14	0,2849	0,2301	0,0001
15	0,2664	0,2314	0,0001
16	0,2646	0,2347	0,0001
17	0,2495	0,2215	0,0001
18	0,2404	0,2157	0,0001
19	0,2296	0,2091	0,0001
20	0,2254	0,2059	0,0001
21	0,2524	0,2057	0,0001
22	0,2437	0,2241	0,0001
23	0,2375	0,2235	0,0001
24	0,2391	0,2206	0,0001
25	0,2315	0,2131	0,0001
26	0,2325	0,2066	0,0001
27	0,2235	0,1985	0,0001
28	0,2223	0,1993	0,0001
29	0,2215	0,1977	0,0001
30	0,221	0,1929	0,0001

31	0,2206	0,192	0,0001
32	0,2085	0,1919	0,0001
33	0,2063	0,1878	0,0001
34	0,2077	0,1935	0,0001
35	0,2057	0,2155	0,0001
36	0,2021	0,2318	0,0001
37	0,2003	0,1915	0,0001
38	0,1934	0,1849	0,0001
39	0,1931	0,1844	0,0001
40	0,1875	0,1714	0,0001
41	0,1812	0,1615	0,00005
42	0,1813	0,1682	0,00005
43	0,1728	0,1592	0,00005
44	0,1703	0,1625	0,00005
45	0,1692	0,1692	0,00005
46	0,1783	0,1942	0,00005
47	0,1791	0,1952	0,00005
48	0,1814	0,1915	0,00005
49	0,1743	0,1825	0,00005
50	0,1741	0,1845	0,00005
51	0,1824	0,1924	0,00005
52	0,1811	0,1912	0,00005
53	0,1745	0,1932	0,00005
54	0,1652	0,1742	0,00005
55	0,1604	0,1778	0,00005
56	0,1586	0,1839	0,00005
57	0,166	0,1789	0,00005
58	0,1597	0,1792	0,00005
59	0,1562	0,1743	0,00005
60	0,155	0,1745	0,00005
61	0,1647	0,1775	6,25E-06
62	0,1586	0,1738	6,25E-06
63	0,1577	0,1782	6,25E-06
64	0,1538	0,1814	6,25E-06
65	0,163	0,1785	6,25E-06

Model **65 epoch** boyunca eğitilmiş ve **early stopping** uygulanmıştır. Eğitim ve doğrulama kayıpları istikrarlı biçimde azalmış; öğrenme oranı **41. epoch'tan itibaren 1e-4 → 5e-5**, **61. epoch'tan sonra ise 6.25e-6** seviyesine düşürülmüştür. Bu, modelin ince ayar yaparak daha iyi genelleme sağlaması için uygulanmıştır. Son doğrulama kaybı **0.1785**, eğitim kaybı ise **0.1630** olarak gerçekleşmiştir.

MSE: 107219823624192.00
MAE: 7194386.00
RMSE: 10354700.56
R²: 0.8121
MAPE: 50.65%
Training Time: 265.71 seconds

Inference Time: 0.1692 seconds

III. Reformer Modeli

Reformer, klasik Transformer modelinin sınırlamalarını (özellikle uzun dizilerdeki bellek ve hız sorunlarını) çözmek için geliştirilmiş verimli bir Transformer varyantıdır.

Google Research tarafından 2020'de tanıtılmıştır.

-Nasıl çalışır?

- Klasik attention mekanizması yerine LSH Attention (Locality-Sensitive Hashing) kullanır. Bu, sadece benzer token'lar arasında attention hesaplamasını sağlar.
- Reversible Layers: Geriye doğru geçiş sırasında ara katman çıktıları bellekte tutulmaz, hesaplanır. Böylece bellek verimli kullanılır.

Sonuçlar

Epoch	Train Loss	Val Loss	Learning Rate
1	0,7876	0,5117	0,0001
2	0,4651	0,3678	0,0001
3	0,3454	0,3862	0,0001
4	0,3066	0,2803	0,0001
5	0,2771	0,2561	0,0001
6	0,2553	0,2194	0,0001
7	0,2437	0,2391	0,0001
8	0,2313	0,2343	0,0001
9	0,2218	0,2315	0,0001
10	0,2083	0,2452	0,0001
11	0,2008	0,2411	0,0001
12	0,1931	0,2307	0,0001
13	0,1898	0,2114	0,0001
14	0,1808	0,2104	0,0001
15	0,1771	0,2048	0,0001
16	0,1785	0,2334	0,0001
17	0,1693	0,2232	0,0001
18	0,1621	0,211	0,0001
19	0,1604	0,2118	0,0001
20	0,1539	0,2011	0,0001
21	0,1594	0,1966	0,0001
22	0,1454	0,1664	0,0001
23	0,1454	0,1964	0,0001
24	0,1437	0,1996	0,0001
25	0,1428	0,1945	0,0001
26	0,1319	0,1667	0,0001
27	0,1272	0,1775	0,0001
28	0,1426	0,1832	0,00005
29	0,1314	0,1873	0,00005
30	0,1216	0,2014	0,00005

31	0,1279	0,1991	0,00005
32	0,1249	0,184	0,00005

Model **32 epoch** boyunca eğitilmiş ve **early stopping** uygulanmıştır. Eğitim ve doğrulama kayıpları düzenli biçimde azalmış; **26. epoch'tan itibaren öğrenme oranı $1e-4 \rightarrow 5e-5$** seviyesine düşürülmüştür. Bu ayarlama, doğrulama performansını dengelemek amacıyla yapılmıştır. Son doğrulama kaybı **0.1840**, eğitim kaybı ise **0.1249** olarak gerçekleşmiştir.

IV. TFT Modeli

TFT, çok değişkenli zaman serisi tahmini için geliştirilmiş, yüksek doğruluk ve yorumlanabilirlik sunan, kompleks ve güçlü bir modeldir. Google DeepMind tarafından 2020'de tanıtılmıştır.

-Nasıl çalışır?

- Hem zamanla değişen (time-varying) hem de sabit (static) girdileri işler.
- Gated Residual Network ve Variable Selection Network ile önemli öznitelikleri seçer.
- Attention katmanları, hangi zaman aralığı ve özelliğin önemli olduğunu açıklar.

Sonuçlar

Epoch	Train Loss	Val Loss	Learning Rate
1	0,7223	0,4627	0,0001
2	0,4424	0,391	0,0001
3	0,3664	0,3794	0,0001
4	0,3222	0,3309	0,0001
5	0,2834	0,3062	0,0001
6	0,2533	0,2871	0,0001
7	0,2378	0,2609	0,0001
8	0,2156	0,2622	0,0001
9	0,2106	0,2641	0,0001
10	0,1902	0,2291	0,0001
15	0,1448	0,2391	0,0001
20	0,1442	0,2211	0,0001
25	0,1183	0,2289	0,0001
28	0,1138	0,232	0,0001
30	0,1057	0,2065	0,0001
35	0,1019	0,1894	0,0001
40	0,1023	0,1949	0,0001

Model **42 epoch** boyunca eğitilmiş ve **early stopping** uygulanmıştır. Eğitim ve doğrulama kayıpları düzenli biçimde azalmış, model stabil bir şekilde öğrenmiştir. Öğrenme oranı sabit tutulmuş (varsayılan: **$1e-4$**). Son epoch'ta doğrulama kaybı **0.1949**, eğitim kaybı ise **0.1023** olarak gerçekleşmiştir.

MSE: 119992662097920.0000
MAE: 8040703.0000
RMSE: 10954116.2171
R2: 0.7897
MAPE: 82.59%
Train time: 32.88s
Inference time: 0.03s

V. TST Modeli

TST, klasik Transformer mimarisinin zaman serisi tahmini problemlerine doğrudan uygulanmasıyla geliştirilen bir modeldir

-Nasıl çalışır?

- Zaman serisi verisine pozisyonel encoding eklenir.
- Genellikle sadece Encoder kısmı kullanılır.
- Model doğrudan geçmiş veriye bakarak gelecekteki değerleri tahmin eder.

Sonuçlar

Epoch	Train Loss	Val Loss	Learning Rate
1	0,8984	0,6328	4,26E-05
2	0,7278	0,6182	5,25E-05
3	0,6155	0,5535	0,000063
4	0,4995	0,4534	8,17E-05
5	0,4007	0,4258	0,000115
6	0,3328	0,3827	0,000132
7	0,2664	0,3457	0,00016
8	0,2402	0,2477	0,000199
9	0,2021	0,2832	0,000213
10	0,1705	0,2681	0,000221
15	0,1111	0,2026	0,000572
21	0,0917	0,2635	0,000284
26	0,0755	0,2068	0,000908
31	0,0815	0,2543	0,000999
36	0,0463	0,2505	0,00129
41	0,0376	0,2317	0,00094
46	0,0321	0,2629	0,000875

Model **50 epoch** boyunca eğitilmiş ve **early stopping** uygulanmıştır. Eğitim kaybı istikrarlı bir şekilde azalmış; öğrenme oranı çeşitli aşamalarda dinamik olarak ayarlanmıştır. Bu strateji doğrulama performansını iyileştirmeyi hedeflemiştir. Son epoch'ta doğrulama kaybı **0.2629**, eğitim kaybı ise **0.0321** olarak gerçekleşmiştir.

Eğitim süresi: 47.53 saniye
MSE: 114628331831296.0000
MAE: 7729483.5000
RMSE: 10706462.1529
R² Skoru: 0.7991
MAPE: 81.92%

References

- [1] [COLAB NOTEBOOKS , GRAFİKLER VE VERİLER](#)